

بسم الله الرحمن الرحيم

نام مقاله: Proximal Policy Optimization Algorithms

نویسندگان: John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, Oleg

Klimov (OpenAI) - ژورنال و ناشر: arXiv Preprint (OpenAI) / CoRR

سال چاپ: ۲۰۱۷

فیلد

|                                                                                                               |                                      |
|---------------------------------------------------------------------------------------------------------------|--------------------------------------|
| J. Schulman et al., "Proximal Policy Optimization Algorithms," arXiv preprint arXiv:1707.06347, 2017          | مرجع کامل                            |
| واگرایی و بهرورسانی های مخرب در روش های سنتی گرادین سیاست و پیچیدگی بالای پیاده سازی روش های مقید مانند TRPO  | مسئله                                |
| PPO با استفاده از تابع هدف <b>Clipped Surrogate</b> جهت محدود کردن تغییرات سیاست در یک بازه امن               | روش                                  |
| بردارهای وضعیت (States) مستخرج از تله متری (یا GNN)، پاداش ها (Rewards) و تخمین های مزیت (Advantages)         | ورودی (INPUT)                        |
| سیاست بهینه ( $\pi$ ) و تابع ارزش ( $V$ ) برای اتخاذ کنش های مدیریت ترافیک                                    | خروجی                                |
| مقید کردن نسبت احتمال سیاست ( $r_t$ ) یک حد پایین بدبینانه (Pessimistic Bound) برای بهبود عملکرد فراهم می کند | فرضیات کلیدی مقاله                   |
| ابداع مکانیزم <b>Clipping</b> برای جایگزینی قیدهای سخت ریاضی با یک تابع هدف ساده و کارآمد                     | نوآوری                               |
| حساسیت به انتخاب های پارامتر $\epsilon$ و ضریب بونوس انتروپی در سناریوهای بسیار پیچیده                        | محدودیت                              |
| بهینه سازی مرتبه اول (First-order) با پیچیدگی بسیار کمتر از TRPO و کارایی نمونه برداری بالا                   | پیچیدگی محاسباتی و زمان اجرا         |
| میانگین پاداش تجمعی در محیط های MuJoCo و بازی های Atari                                                       | معیارهای ارزیابی و بسترهای شبیه سازی |
| موتور تصمیم گیر در <b>xApp</b> ؛ تضمین پایداری شبکه همراه اول با جلوگیری از تغییرات ناگهانی و مخرب در مسیرها  | رابط به نورو-باتلنک                  |
| فصل ۲ (مبانی DRL) و فصل ۳ (طراحی عامل هوشمند مقید)                                                            | فصل پایان نامه                       |

فرمول بندی تابع زیان ترکیبی ( $L^{CLIP+VF+S}$ ) و استفاده از **GAE** برای کاهش واریانس در شبکه اپراتوری

ایده قابل استفاده  
(در کدنویسی یا  
فرمول بندی)

#### ❖ خلاصه برداشت شده از سند :

این سند، معرف الگوریتم **PPO** به عنوان یکی از پایدارترین و کارآمدترین روش های یادگیری تقویتی عمیق است که هدف اصلی آن حل چالش "به روزرسانی های افراطی سیاست" می باشد. در محیط های پویایی مانند شبکه همراه اول، اعمال یک سیاست مسیریابی جدید که تفاوت فاحشی با وضعیت قبلی داشته باشد، می تواند منجر به سقوط ناگهانی کیفیت سرویس (**Performance Collapse**) شود. PPO با معرفی مکانیزم **Clipped Surrogate Objective**، نسبت تغییرات سیاست جدید به قدیم را در یک بازه امن (معمولاً بین ۰.۸ تا ۱.۲) مقید می کند.

در چارچوب **نوروباتل نک**، این الگوریتم به عنوان مغز متفکر لایه تصمیم گیر عمل می کند. این سند تبیین می کند که چگونه می توان با استفاده از معماری مشترک (**Shared Anatomy**)، ویژگی های گرافی استخراج شده توسط **GraphSAGE** را همزمان برای ارزیابی وضعیت (**Critic**) و صدور فرامین اصلاحی (**Actor**) به کار گرفت. همچنین، وجود **بونوس انتروپی** در فرمول بندی این مقاله، تضمین کننده این است که عامل هوشمند ما در مواجهه با شرایط جدید ترافیکی (مانند Flash Crowd)، از کاوش برای یافتن مسیرهای جایگزین باز نماند.