



گزارش فاز ۱

عنوان پایان نامه:

ارتقای تاب آوری شبکه با معماری ترکیبی برش های دقیق
و یادگیری تقویتی عمیق

شناسایی، پیش بینی و مدیریت پیش دستانه گلوگاه های ترافیکی در شبکه های خودران با تلفیق ساختار های
پیشین ریاضی، شبکه های عصبی گراف و یادگیری تقویتی عمیق

نام و نام خانوادگی دانشجو: محمد مهدی شفیقی

مقطع: کارشناسی ارشد

دانشگاه: شاهد-تهران

استادراهنما: جناب آقای دکتر اردشیر دولتی

همراه پژوه: جناب آقای دکتر قائمی نیا

تاریخ: خرداد ماه ۱۴۰۵

چکیده:

توسعه شبکه های نسل پنجم پیشرفته (5G-Advanced) و معماری های نوین مخابراتی نظیر O-RAN، نیازمند گذار از مدیریت دستی و ایستای شبکه به سمت ساختارهای خودگردان (Autonomous Networks) است. شناسایی دقیق، بلادرنگ و تعمیم پذیر گلوگاه های ترافیکی (Network Bottlenecks) یکی از چالش های اساسی در اپراتورهای بزرگ مخابراتی است.

در این گزارش (فاز ۱)، چارچوب مفهومی پلتفرم *NeuroBottleneck* تبیین شده است. این چارچوب با تلفیق استاندارد های مدیریت خودگردان محاسباتی (3GPP/ETSI) و معماری باز-O-RAN یک مدل مدیریت بسته (Closed-Loop) را پایه ریزی می کند. در بخش متدولوژی هوش مصنوعی، محدودیت روش های سنتی با بکارگیری یادگیری استقرایی گراف (GraphSAGE) برطرف شده و پایداری به روزرسانی های ساختار ترافیکی با استفاده از الگوریتم بهینه سازی سیاست پروکسیمال (PPO) تضمین می گردد (لازم به ذکر است که تابع پاداش بهینه هنوز در حال توسعه و در مرحله نهایی سازی است).

در نهایت، با ادغام شبکه عصبی گرافی و یادگیری تقویت پذیر (تقویتی)، یک فضای اقدام مبتنی بر مسیر (Path-based Action Space) طراحی شده است که تعمیم پذیری مدل را روی توپولوژی های ناشناخته و متغیر شبکه مخابراتی تضمین می کند. ساختار مخزن پیاده سازی صنعتی این پلتفرم نیز در گام های اولیه روی گیت هاب پیاده سازی و ساختاردهی شده است.

فهرست مطالب

۱. مقدمه و بیان مسئله (چارچوب استانداردهای مخابراتی)..... ۴
۲. مبانی نظری و متدولوژی هوش مصنوعی..... ۷
 - ۱) یادگیری ویژگی های ساختاری گراف با روش استقرایی (GraphSAGE)..... ۷
 - ۲) بهینه سازی سیاست پایدار با الگوریتم PPO..... ۹

۱. مقدمه و بیان مسئله (چارچوب استانداردهای مخابراتی)

ارزیابی و شناسایی گلوگاه های ترافیکی و مدیریت نوسانات ناگهانی در شبکه های سلولی مدرن، نیازمند اتوماسیون سطح بالا بر پایه تحلیل های هوشمند است. بر اساس استاندارد مدیریت خودگردان 3GPP/ETSI، سیستم مدیریت شبکه باید بتواند ابعاد سه گانه ای شامل سناریوهای مدیریتی، قلمرو مدیریت و جریان کاری بسته را پوشش دهد. چالش اصلی در شبکه های فعلی، اتکای بیش از حد به مداخله عامل انسانی در فازهای تحلیل ریشه خطا (RCA) و تصمیم گیری بهینه سازی است که منجر به افزایش تاخیر در رفع احتقان شبکه می گردد.




Figure 4.3.3-1: Autonomy for different management scope

پلتفرم پیشنهادی *NeuroBottleneck*، فرآیند بهینه سازی ترافیک را در سطح کارهای کلیدی تعریف شده در استاندارد، شامل شناسایی اتوماتیک مشکلات توپولوژیک (Task D)، پیش بینی افت کیفیت سرویس (Task E)، تحلیل ریشه خطا (Task G) و اصلاح هوشمند مسیر یا تخصیص منابع (Task H) بازتعریف می کند.

معماری پیشنهادی سیستم *NeuroBottleneck* با هدف ارتقای سطح خودگردانی شبکه به سطح ۴ (Advanced Autonomous Network)، فرآیند های عملیاتی خود را کاملاً بر جریان کاری استاندارد ETSI TS 128 100 منطبق ساخته است.

در این ساختار هوشمند، ماژول GNN با کالبدشکافی تله متری دریافتی از لایه NWDAF، وظیفه شناسایی مسائل شبکه (Task D: Network issues identification) را بر عهده دارد و با تکیه بر تحلیل پیش دستانه، به پیش بینی افت عملکرد (Task E: Network deterioration prediction) در سناریوهای بحرانی نظیر ترافیک انفجاری (Flash Crowd) می پردازد.

همچنین، تلفیق مدل های ریاضیاتی دقیق نظیر درخت گوموری-هو (Gomory-Hu Tree) در این معماری، امکان تحلیل ریشه خطای شبکه (Task G: Network issue root cause analysis) را به صورت ساختاری فراهم آورده تا محل دقیق فیزیکی گلوگاه ها شناسایی شود.

در لایه نهایی تصمیم گیری، عامل DRL با دریافت این محدودیت های توپولوژیک، به تحلیل راهکارهای تنظیم شبکه (Task H: Network adjustment solutions analysis) می پردازد تا بهینه ترین راهکارهای بازمسیریابی (Rerouting) را جهت تضمین تاب آوری و شاخص های SLA اپراتور همراه اول تولید نماید.

Table 5-1: Framework approach for evaluating autonomous network levels

Autonomous network level		Task categories				
		Execution	Awareness	Analysis	Decision	Intent handling
L0	Manual operating network	Human	Human	Human	Human	Human
L1	Assisted operating network	Human & Telecom system	Human & Telecom system	Human	Human	Human
L2	Preliminary autonomous network	Telecom system	Human & Telecom system	Human & Telecom system	Human	Human
L3	Intermediate autonomous network	Telecom system	Telecom system	Human & Telecom system	Human & Telecom system	Human
L4	Advanced autonomous network	Telecom system	Telecom system	Telecom system	Telecom system	Human & Telecom system
L5	Full autonomous network	Telecom system	Telecom system	Telecom system	Telecom system	Telecom system
NOTE 1: Human reviewed decision have the highest authority in each level if there is any confliction between human reviewed decision and telecom system generated decision.						
NOTE 2: The order of above five task categories does not reflect the workflow sequence.						

Level 0 manual operating network: No categorization of the tasks is accomplished by telecom system itself.

Level 1 assisted operating network: A part of the execution and awareness tasks are accomplished automatically by telecom system itself based on human defined control information. At this level, telecom system can assist human to improve the execution and awareness efficiency.

Level 2 preliminary autonomous network: All the execution tasks are accomplished automatically by telecom system itself. A part of the awareness and analysis tasks are accomplished automatically by telecom system itself based on human defined control information. At this level, telecom system can assist human to achieve the closed loop based on human defined control information.

Level 3 intermediate autonomous network: All the execution and awareness tasks are accomplished automatically by telecom system itself. A part of the analysis and decision tasks are accomplished automatically by telecom system itself based on human defined control information. At this level, the telecom system can achieve the closed loop automation based on the human defined closed loop automation control information.

Level 4 advanced autonomous network: All the execution, awareness, analysis and decision tasks are accomplished automatically by telecom system itself. And intent handling tasks can be partly accomplished automatically by telecom system itself based on human defined intent handling control information. At this level, telecom system can achieve the intent driven closed loop automation based on human defined intent handling control information, which means the telecom system can translate the intent to the detailed closed loop automation control information and translate the detailed network and service information to intent fulfilment information (e.g. the intent is satisfied or not) based on human defined

هدف این پژوهش، ارتقای سطح خودگردانی شبکه از سطوح سنتی به سطح ۳ (Intermediate) و سطح ۴ (Advanced) است؛ جایی که سیستم تله کام قادر است بر اساس خط مشی های تعیین شده، وظایف تحلیل و تصمیم گیری را به صورت پویا و خودمختار در مواجهه با گلوگاه ها انجام دهد.

جهت پیاده سازی این ساختار خودگردان در لایه دسترسی رادیویی، معماری O-RAN ساختار منطقی لازم را فراهم می‌آورد. عملیات بهینه سازی ترافیک و رفع گلوگاه ها در این معماری، درون کنترل کننده هوشمند شبکه رادیویی در زمان غیربلادرنگ (Non-RT RIC) و زمان نزدیک به بلادرنگ (Near-RT RIC) تعبیه می‌شود.



O-RAN.WG1.TS.OAD-R005-v16.00




Figure 5.1-1: High Level Architecture of O-RAN

این پلتفرم با تحلیل کلان داده های شبکه در لایه SMO و از طریق روتین های *rApp*، سیاست های بهینه سازی ترافیک را فرموله کرده و از طریق اینترفیس استاندارد A1 به صورت هدایت سیاست (Policy Guidance) به Near-RT RIC منتقل می‌کند تا در بازه های زمانی کمتر از ۱۰۰ میلی ثانیه، اقدامات اصلاحی روی المان های شبکه اعمال شوند




Figure 5.2-1: O-RAN Control Loops

عملا عامل هوشمند سیستم **NeuroBottleneck** ما در دو ماژول از بخش های **O-RAN** و **SMO** که به ترتیب در زمان غیربلادرنگ (**Non-RT RIC**) و زمان نزدیک به بلادرنگ (**Near-RT RIC**) هستند نصب و اجرای همزمان می شوند.




Figure 5.3.2-1: Service-based representation of Near-RT RIC as specified in Near-RT RIC Architecture [26]

۲. مبانی نظری و متدولوژی هوش مصنوعی

۱. یادگیری ویژگی های ساختاری گراف با روش استقرایی (**GraphSAGE**)

روش های سنتی یادگیری امبدینگ گراف (مانند Node2Vec) ماهیتی ترانزداکتیو (Transductive) دارند و نیازمند حضور تمامی گره ها در طول فرآیند آموزش هستند، امری که بکارگیری آن ها را در توپولوژی های پویا و در حال تغییر شبکه های مخابراتی غیرممکن می سازد.




Figure 1: Visual illustration of the **GraphSAGE** sample and aggregate approach.

An inductive framework must learn to recognize structural properties of a node's neighborhood that reveal both the node's local role in the graph, as well as its global position.

در پلتفرم *NeuroBottleneck*، از چارچوب استقرایی (Inductive) الگوریتم GraphSAGE استفاده می‌شود تا مدل بتواند بدون نیاز به آموزش مجدد، امبدینگ‌های ساختاری باکیفیتی را برای گره‌ها یا لینک‌های جدید شبکه سلولی تولید کند.

فرآیند انتشار رو به جلو (Forward Propagation) در این الگوریتم به گونه‌ای است که در هر لایه از گراف، ویژگی‌های یک گره بر اساس تجمع (Aggregation) ویژگی‌های یک نمونه برداری تصادفی و یکنواخت با اندازه ثابت (S_k) از همسایگی محلی آن به روزرسانی می‌شود.

تابع تجمع Pooling به دلیل ویژگی تقارن و قدرت تفکیک بالا در کارهای ساختاری، به عنوان هسته اصلی استخراج ویژگی‌های گلوگاه انتخاب شده است

$$\text{AGGREGATE}_k^{\text{pool}} = \max(\{\sigma(\mathbf{W}_{\text{pool}} \mathbf{h}_{u_i}^k + \mathbf{b}), \forall u_i \in \mathcal{N}(v)\}), \quad (3)$$

فرآیند آموزش بدون نظارت مدل بر پایه یک تابع زیان مبتنی بر گشت تصادفی (Random Walk Loss) استوار است که گره‌های همسایه را در فضای امبدینگ به یکدیگر نزدیک و گره‌های دور را متمایز می‌سازد:

$$J_G(\mathbf{z}_u) = -\log(\sigma(\mathbf{z}_u^T \mathbf{z}_v)) - Q \cdot \mathbb{E}_{v_n \sim P_n(v)} \log(\sigma(-\mathbf{z}_u^T \mathbf{z}_{v_n})), \quad (1)$$

جهت مقیاس‌پذیری در ابعاد صنعتی شبکه همراه اول، از رویکرد مینی بیچ الگوریتم استفاده می‌شود تا محاسبات بر خلاف متدهای مرسوم گراف کامل، به اندازه مینی بیچ مقید گردد.

Table 1: **Prediction results for the three datasets** (micro-averaged F1 scores). Results for unsupervised and fully supervised GraphSAGE are shown. Analogous trends hold for macro-averaged scores.

Name	Citation		Reddit		PPI	
	Unsup. F1	Sup. F1	Unsup. F1	Sup. F1	Unsup. F1	Sup. F1
Random	0.206	0.206	0.043	0.042	0.396	0.396
Raw features	0.575	0.575	0.585	0.585	0.422	0.422
DeepWalk	0.565	0.565	0.324	0.324	—	—
DeepWalk + features	0.701	0.701	0.691	0.691	—	—
GraphSAGE-GCN	0.742	0.772	0.908	0.930	0.465	0.500
GraphSAGE-mean	0.778	0.820	0.897	0.950	0.486	0.598
GraphSAGE-LSTM	0.788	0.832	0.907	0.954	0.482	0.612
GraphSAGE-pool	0.798	0.839	0.892	0.948	0.502	0.600
% gain over feat.	39%	46%	55%	63%	19%	45%




Figure 2: A: Timing experiments on Reddit data, with training batches of size 512 and inference on the full test set (79,534 nodes). B: Model performance with respect to the size of the sampled neighborhood, where the “neighborhood sample size” refers to the number of neighbors sampled at each depth for $K = 2$ with $S_1 = S_2$ (on the citation data using GraphSAGE-mean).

۲. بهینه سازی سیاست پایدار با الگوریتم PPO

اعمال تغییرات ناگهانی و بزرگ در سیاست های مسیریابی یا تخصیص منابع ترافیکی می تواند منجر به نوسانات شدید، سقوط کیفیت سرویس (QoS) و ناپایداری کل شبکه شود.




Figure 1: Plots showing one term (i.e., a single timestep) of the surrogate function L^{CLIP} as a function of the probability ratio r , for positive advantages (left) and negative advantages (right). The red circle on each plot shows the starting point for the optimization, i.e., $r = 1$. Note that L^{CLIP} sums many of these terms.

الگوریتم PPO با معرفی تابع هدف مقید شده (Clipped Surrogate Objective)، مانع از بهروزرسانی های افراطی در سیاست عامل هوشمند می شود. این مکانیزم پایداری محاسباتی بالایی را در مواجهه با بارهای ترافیکی شدید (Traffic Spikes) فراهم می کند. تابع هدف اصلی این الگوریتم به صورت زیر فرمول بندی می گردد:

$$L^{CLIP}(\theta) = \hat{\mathbb{E}}_t \left[\min(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t) \right] \quad (7)$$

در این ساختار، نسبت احتمال سیاست جدید به قدیم ($r_t(\theta)$) در بازه $[1 - \epsilon, 1 + \epsilon]$ مقید می شود تا گام های بهینه سازی شبکه کاملاً محافظه کارانه و پایدار برداشته شوند.

Table 3: **PPO hyperparameters** used for the Mujoco 1 million timestep benchmark.

Hyperparameter	Value
Horizon (T)	512
Adam stepsize	*
Num. epochs	15
Minibatch size	4096
Discount (γ)	0.99
GAE parameter (λ)	0.95
Number of actors	32 (locomotion), 128 (flagrun)
Log stdev. of action distribution	LinearAnneal(-0.7, -1.6)

همچنین معماری پلتفرم بر پایه ساختار مشترک (Shared Anatomy) هم زمان تابع ارزش و سیاست-Actor (Critic) تنظیم شده و با افزودن بونوس انتروپی، کاوش (Exploration) بهینه در فضای وضعیت شبکه تضمین می‌شود.

اگر از معماری شبکه عصبی استفاده شود که پارامتر ها را بین سیاست - تابع ارزش به اشتراک می‌گذارد باید از تابع زیانی استفاده کنیم که جایگزین سیاست را با جمله خطای تابع ارزش ترکیب می‌کند finite-horizon estimators in [Mni+16]. If using a neural network architecture that shares parameters between the policy and value function, we must use a loss function that combines the policy surrogate and a value function error term. This objective can further be augmented by adding an entropy bonus to ensure sufficient exploration, as suggested in past work [Wil92; Mni+16]. Combining these terms, we obtain the following objective, which is (approximately) maximized each iteration: این تابع هدف می‌تواند با اضافی کردن یک بونوس انتروپی برای اطمینان از کاوش کافی، بیشتر تقویت شود

$$L_t^{CLIP+VF+S}(\theta) = \hat{\mathbb{E}}_t[L_t^{CLIP}(\theta) - c_1 L_t^{VF}(\theta) + c_2 S[\pi_\theta](s_t)], \quad (9)$$

۳. معماری چارچوب پیشنهادی (تلفیق GNN و یادگیری تقویتی)

هسته اصلی پلتفرم *NeuroBottleneck* در نقطه تلاقی مدل سازی گرافی و یادگیری تقویتی عمیق (DRL+GNN) شکل می‌گیرد. شبکه های عصبی سنتی (مانند MLP یا CNN) به دلیل داشتن ابعاد ورودی ثابت، توانایی تعمیم پذیری روی توپولوژی های متغیر مخابراتی را ندارند ، همچنین ...