



گزارش فاز ۱

عنوان پایان نامه:

ارتقای تاب آوری شبکه با معماری ترکیبی برش های دقیق و
یادگیری تقویتی عمیق

شناسایی، پیش بینی و مدیریت پیش دستانه گلوگاه های ترافیکی در شبکه های خودران با تلفیق ساختار های
پیشین ریاضی، شبکه های عصبی گراف و یادگیری تقویتی عمیق

نام و نام خانوادگی دانشجو: محمد مهدی شفیقی

مقطع: کارشناسی ارشد

دانشگاه: شاهد-تهران

استادراهنما: جناب آقای دکتر اردشیر دولتی

همراه پژوه: جناب آقای دکتر قائمی نیا

تاریخ: خرداد ماه ۱۴۰۵

چکیده:

توسعه شبکه های نسل پنجم پیشرفته (5G-Advanced) و معماری های نوین مخابراتی نظیر O-RAN، نیازمند گذار از مدیریت دستی و ایستای شبکه به سمت ساختارهای خودگردان (Autonomous Networks) است. شناسایی دقیق، بلادرنگ و تعمیم پذیر گلوگاه های ترافیکی (Network Bottlenecks) یکی از چالش های اساسی در اپراتورهای بزرگ مخابراتی است.

در این گزارش (فاز ۱)، چارچوب مفهومی پلتفرم *NeuroBottleneck* تبیین شده است. این چارچوب با تلفیق استاندارد های مدیریت خودگردان محاسباتی (3GPP/ETSI) و معماری باز O-RAN، یک مدل مدیریت بسته (Closed-Loop) را پایه ریزی می کند. در بخش متدولوژی هوش مصنوعی، محدودیت روش های سنتی با بکارگیری یادگیری استقرایی گراف (GraphSAGE) برطرف شده و پایداری به روزرسانی های ساختار ترافیکی با استفاده از الگوریتم بهینه سازی سیاست پروکسیمال (PPO) تضمین می گردد (لازم به ذکر است که تابع پاداش بهینه هنوز در حال توسعه و در مرحله نهایی سازی است).

در نهایت، با ادغام شبکه عصبی گرافی و یادگیری تقویت پذیر (تقویتی)، یک فضای اقدام مبتنی بر مسیر (Path-based Action Space) طراحی شده است که تعمیم پذیری مدل را روی توپولوژی های ناشناخته و متغیر شبکه مخابراتی تضمین می کند. ساختار مخزن پیاده سازی صنعتی این پلتفرم نیز در گام های اولیه روی گیت هاب پیاده سازی و ساختاردهی شده است.

فهرست مطالب

۱	مقدمه و بیان مسئله (چارچوب استانداردهای مخابراتی)	۵
۲	مبانی نظری و متدولوژی هوش مصنوعی	۹
۱	یادگیری ویژگی های ساختاری گراف با روش استقرایی (GraphSAGE)	۹
۲	بهینه سازی سیاست پایدار با الگوریتم PPO	۱۱
۳	معماری چارچوب پیشنهادی (تلفیق GNN و یادگیری تقویتی)	۱۲
۴	ساختار پیاده سازی و مخزن توسعه (مستندات گیت هاب)	۱۶
۱۶	چکلیست ارزیابی کیفی و انطباق استاندارد (سند متمم ۷۰ آیتی)	۱۶
۵	چشم انداز و برنامه ریزی توسعه فاز ۲ (شبیه سازی و ارزیابی عملی)	۱۷
i.	استک تکنولوژی و معماری نرم افزاری شبیه ساز	۱۷
ii.	سناریوهای ارزیابی و استقرار (Test Cases)	۱۷
iii.	شاخص های کلیدی عملکرد (KPIs)	۱۸
iv.	مراحل اجرا و یکپارچه سازی	۱۸

فهرست تصاویر

- 1 لایه‌های مدیریت خودگردان و ابعاد ارزیابی استاندارد (Autonomy for different management scope) جهت ارتقای سطح اتوماسیون..... ۵
- 2 معماری سطح بالای O-RAN و تعامل با لایه‌های مدیریت سرویس و ارکستراسیون (SMO)..... ۷
- 3 حلقه‌های کنترلی (Control Loops) در معماری O-RAN بر اساس زمان پاسخ‌دهی (Real-Time, Near-RT, Non-RT)..... ۸
- 4 تعاملات دو لایه Near-RT, Non-RT..... ۸
- 5 نمایی از نحوه عملکرد رویکرد GraphSAGE..... ۹
- 6 آزمایش‌های زمان‌بندی و بررسی عملکرد مدل استقرایی در اندازه‌های مختلف همسایگی..... ۱۰
- 7 مودار رفتار تابع هدف جایگزین مقید (Clipped Surrogate Objective) در الگوریتم PPO برای مزیت‌های مثبت و منفی..... ۱۱
- 8 معماری پیام‌رسانی (Message Passing) در شبکه‌های عصبی گراف جهت به‌روزرسانی ویژگی‌های پنهان لینک‌ها..... ۱۳
- 9 نحوه بازنمایی فضای اقدام مبتنی بر مسیر در وضعیت پنهان لینک‌ها..... ۱۴
- 10 شماتیک تعامل عامل یادگیری تقویتی عمیق (DRL Agent) و شبکه عصبی گراف در سناریوی مسیریابی و کنترل ترافیک..... ۱۵

۱ مقدمه و بیان مسئله (چارچوب استانداردهای مخابراتی)

ارزیابی و شناسایی گلوگاه های ترافیکی و مدیریت نوسانات ناگهانی در شبکه های سلولی مدرن، نیازمند اتوماسیون سطح بالا بر پایه تحلیل های هوشمند است. بر اساس استاندارد مدیریت خودگردان 3GPP/ETSI، سیستم مدیریت شبکه باید بتواند ابعاد سه گانه ای شامل سناریوهای مدیریتی، قلمرو مدیریت و جریان کاری بسته را پوشش دهد. (WG5, 2025) چالش اصلی در شبکه های فعلی، اتکای بیش از حد به مداخله عامل انسانی در فازهای تحلیل ریشه خطا (RCA) و تصمیم گیری بهینه سازی است که منجر به افزایش تاخیر در رفع احتقان شبکه می گردد. (WG5, 2025)




Figure 4.3.3-1: Autonomy for different management scope

لایه های مدیریت خودگردان و ابعاد ارزیابی استاندارد (Autonomy for different management scope) جهت ارتقای سطح اتوماسیون.

پلتفرم پیشنهادی *NeuroBottleneck*، فرآیند بهینه سازی ترافیک را در سطح کارهای کلیدی تعریف شده در استاندارد، شامل شناسایی اتوماتیک مشکلات توپولوژیک (Task D)، پیش بینی افت کیفیت سرویس (Task E)، تحلیل ریشه خطا (Task G) و اصلاح هوشمند مسیر یا تخصیص منابع (Task H) بازتعریف می کند. (WG5, 2025)

معماری پیشنهادی سیستم *NeuroBottleneck* با هدف ارتقای سطح خودگردانی شبکه به سطح ۴ (Advanced Autonomous Network)، فرآیند های عملیاتی خود را کاملاً بر جریان کاری استاندارد ETSI TS 128 100 منطبق ساخته است. (WG5, 2025)

در این ساختار هوشمند، ماژول GNN با کالبدشکافی تله متری دریافتی از لایه NWDAF، وظیفه شناسایی مسائل شبکه (Task D: Network issues identification) را بر عهده دارد و با تکیه بر تحلیل پیش‌دستانه، به پیش‌بینی افت عملکرد (Task E: Network deterioration prediction) در سناریوهای بحرانی نظیر ترافیک انفجاری (Flash Crowd) می‌پردازد. (WG5, 2025)

همچنین، تلفیق مدل‌های ریاضیاتی دقیق نظیر درخت گوموری-هو (Gomory-Hu Tree) در این معماری، امکان تحلیل ریشه خطای شبکه (Task G: Network issue root cause analysis) را به صورت ساختاری فراهم آورده تا محل دقیق فیزیکی گلوگاه‌ها شناسایی شود. (WG5, 2025)

در لایه نهایی تصمیم‌گیری، عامل DRL با دریافت این محدودیت‌های توپولوژیک، به تحلیل راهکارهای تنظیم شبکه (Task H: Network adjustment solutions analysis) می‌پردازد تا بهینه‌ترین راهکارهای بازمسیریابی (Rerouting) را جهت تضمین تاب‌آوری و شاخص‌های SLA اپراتور همراه اول تولید نماید. (WG5, 2025)

Table 5-1: Framework approach for evaluating autonomous network levels

Autonomous network level		Task categories				
		Execution	Awareness	Analysis	Decision	Intent handling
L0	Manual operating network	Human	Human	Human	Human	Human
L1	Assisted operating network	Human & Telecom system	Human & Telecom system	Human	Human	Human
L2	Preliminary autonomous network	Telecom system	Human & Telecom system	Human & Telecom system	Human	Human
L3	Intermediate autonomous network	Telecom system	Telecom system	Human & Telecom system	Human & Telecom system	Human
L4	Advanced autonomous network	Telecom system	Telecom system	Telecom system	Telecom system	Human & Telecom system
L5	Full autonomous network	Telecom system	Telecom system	Telecom system	Telecom system	Telecom system
NOTE 1: Human reviewed decision have the highest authority in each level if there is any conflict between human reviewed decision and telecom system generated decision.						
NOTE 2: The order of above five task categories does not reflect the workflow sequence.						

Level 0 manual operating network: No categorization of the tasks is accomplished by telecom system itself.

Level 1 assisted operating network: A part of the execution and awareness tasks are accomplished automatically by telecom system itself based on human defined control information. At this level, telecom system can assist human to improve the execution and awareness efficiency.

Level 2 preliminary autonomous network: All the execution tasks are accomplished automatically by telecom system itself. A part of the awareness and analysis tasks are accomplished automatically by telecom system itself based on human defined control information. At this level, telecom system can assist human to achieve the closed loop based on human defined control information.

Level 3 intermediate autonomous network: All the execution and awareness tasks are accomplished automatically by telecom system itself. A part of the analysis and decision tasks are accomplished automatically by telecom system itself based on human defined control information. At this level, the telecom system can achieve the closed loop automation based on the human defined closed loop automation control information.

Level 4 advanced autonomous network: All the execution, awareness, analysis and decision tasks are accomplished automatically by telecom system itself. And intent handling tasks can be partly accomplished automatically by telecom system itself based on human defined intent handling control information. At this level, telecom system can achieve the intent driven closed loop automation based on human defined intent handling control information, which means the telecom system can translate the intent to the detailed closed loop automation control information and translate the detailed network and service information to intent fulfilment information (e.g. the intent is satisfied or not) based on human defined

هدف این پژوهش، ارتقای سطح خودگردانی شبکه از سطوح سنتی به سطح ۳ (Intermediate) و سطح ۴ (Advanced) است؛ جایی که سیستم تله کام قادر است بر اساس خط مشی‌های تعیین شده، وظایف تحلیل و تصمیم‌گیری را به صورت پویا و خودمختار در مواجهه با گلوگاه‌ها انجام دهد. (WG5, 2025)

جهت پیاده‌سازی این ساختار خودگردان در لایه دسترسی رادیویی، معماری O-RAN ساختار منطقی لازم را فراهم می‌آورد. عملیات بهینه‌سازی ترافیک و رفع گلوگاه‌ها در این معماری، درون کنترل‌کننده هوشمند شبکه رادیویی در زمان غیربلادرنگ (Non-RT RIC) و زمان نزدیک به بلادرنگ (Near-RT RIC) تعبیه می‌شود. (WG1, 2026)



O-RAN.WG1.TS.OAD-R005-v16.00




Figure 5.1-1: High Level Architecture of O-RAN

۲ معماری سطح بالای O-RAN و تعامل با لایه‌های مدیریت سرویس و ارکستراسیون (SMO).

این پلتفرم با تحلیل کلان‌داده‌های شبکه در لایه SMO و از طریق روتین‌های *rApp*، سیاست‌های بهینه‌سازی ترافیک را فرموله کرده و از طریق اینترفیس استاندارد A1 به صورت هدایت سیاست (Policy Guidance) به Near-RT RIC منتقل می‌کند تا در بازه‌های زمانی کمتر از ۱۰۰ میلی‌ثانیه، اقدامات اصلاحی روی المان‌های شبکه اعمال شوند. (WG1, 2026)




Figure 5.2-1: O-RAN Control Loops

۳ حلقه‌های کنترلی (Control Loops) در معماری O-RAN بر اساس زمان پاسخ‌دهی (Real-Time, Near-RT, Non-RT).

عملاً عامل هوشمند سیستم **NeuroBottleneck** ما در دو ماژول از بخش‌های O-RAN و SMO که به ترتیب در زمان غیربلادرنگ (Non-RT RIC) و زمان نزدیک به بلادرنگ (Near-RT RIC) هستند نصب و اجرای همزمان می‌شوند. (WG1, 2026)




Figure 5.3.2-1: Service-based representation of Near-RT RIC as specified in Near-RT RIC Architecture [26]

۴ تعاملات دو لایه Near-RT, Non-RT

۲ مبانی نظری و متدولوژی هوش مصنوعی

۱ یادگیری ویژگی های ساختاری گراف با روش استقرایی (GraphSAGE)

روش های سنتی یادگیری امبدینگ گراف (مانند Node2Vec) ماهیتی ترانزداکتیو (Transductive) دارند و نیازمند حضور تمامی گره ها در طول فرآیند آموزش هستند، امری که بکارگیری آن ها را در توپولوژی های پویا و در حال تغییر شبکه های مخابراتی غیرممکن می سازد. (William L. Hamilton, 2017)




Figure 1: Visual illustration of the **GraphSAGE** sample and aggregate approach.

An inductive framework must learn to

recognize structural properties of a node's neighborhood that **reveal** both **the node's local role** in the graph, as well as **its global position**.

نمایی از نحوه عملکرد رویکرد GraphSAGE

در پلتفرم *NeuroBottleneck*، از چارچوب استقرایی (Inductive) الگوریتم GraphSAGE استفاده می شود تا مدل بتواند بدون نیاز به آموزش مجدد، امبدینگ های ساختاری باکیفیتی را برای گره ها یا لینک های جدید شبکه سلولی تولید کند. (William L. Hamilton, 2017)

فرآیند انتشار رو به جلو (Forward Propagation) در این الگوریتم به گونه ای است که در هر لایه از گراف، ویژگی های یک گره بر اساس تجمع (Aggregation) ویژگی های یک نمونه برداری تصادفی و یکنواخت با اندازه ثابت (S_k) از همسایگی محلی آن به روزرسانی می شود. (William L. Hamilton, 2017)

تابع تجمع Pooling به دلیل ویژگی تقارن و قدرت تفکیک بالا در کارهای ساختاری، به عنوان هسته اصلی استخراج ویژگی های گلوگاه انتخاب شده است

$$\text{AGGREGATE}_k^{\text{pool}} = \max(\{\sigma(\mathbf{W}_{\text{pool}} \mathbf{h}_{u_i}^k + \mathbf{b}), \forall u_i \in \mathcal{N}(v)\}), \quad (3)$$

فرآیند آموزش بدون نظارت مدل بر پایه یک تابع زیان مبتنی بر گشت تصادفی (Random Walk Loss) استوار است که گره های همسایه را در فضای امبدینگ به یکدیگر نزدیک و گره های دور را متمایز می سازد:

$$J_G(\mathbf{z}_u) = -\log(\sigma(\mathbf{z}_u^T \mathbf{z}_v)) - Q \cdot \mathbb{E}_{v_n \sim P_n(v)} \log(\sigma(-\mathbf{z}_u^T \mathbf{z}_{v_n})), \quad (1)$$

جهت مقیاس پذیری در ابعاد صنعتی شبکه همراه اول، از رویکرد مینی بیچ الگوریتم استفاده می شود تا محاسبات بر خلاف متدهای مرسوم گراف کامل، به اندازه مینی بیچ مقید گردد. (William L. Hamilton, 2017)

Table 1: Prediction results for the three datasets (micro-averaged F1 scores). Results for unsupervised and fully supervised GraphSAGE are shown. Analogous trends hold for macro-averaged scores.

Name	Citation		Reddit		PPI	
	Unsup. F1	Sup. F1	Unsup. F1	Sup. F1	Unsup. F1	Sup. F1
Random	0.206	0.206	0.043	0.042	0.396	0.396
Raw features	0.575	0.575	0.585	0.585	0.422	0.422
DeepWalk	0.565	0.565	0.324	0.324	—	—
DeepWalk + features	0.701	0.701	0.691	0.691	—	—
GraphSAGE-GCN	0.742	0.772	0.908	0.930	0.465	0.500
GraphSAGE-mean	0.778	0.820	0.897	0.950	0.486	0.598
GraphSAGE-LSTM	0.788	0.832	0.907	0.954	0.482	0.612
GraphSAGE-pool	0.798	0.839	0.892	0.948	0.502	0.600
% gain over feat.	39%	46%	55%	63%	19%	45%




Figure 2: A: Timing experiments on Reddit data, with training batches of size 512 and inference on the full test set (79,534 nodes). B: Model performance with respect to the size of the sampled neighborhood, where the “neighborhood sample size” refers to the number of neighbors sampled at each depth for $K = 2$ with $S_1 = S_2$ (on the citation data using GraphSAGE-mean).

عر آزمایش های زمان بندی و بررسی عملکرد مدل استقرایی در اندازه های مختلف همسایگی.

۲ بهینه سازی سیاست پایدار با الگوریتم PPO

اعمال تغییرات ناگهانی و بزرگ در سیاست های مسیریابی یا تخصیص منابع ترافیکی می تواند منجر به نوسانات شدید، سقوط کیفیت سرویس (QoS) و ناپایداری کل شبکه شود. (John Schulman, 2017)




Figure 1: Plots showing one term (i.e., a single timestep) of the surrogate function L^{CLIP} as a function of the probability ratio r , for positive advantages (left) and negative advantages (right). The red circle on each plot shows the starting point for the optimization, i.e., $r = 1$. Note that L^{CLIP} sums many of these terms.

$\mathcal{V}$ مودار رفتار تابع هدف جایگزین مقید (Clipped Surrogate Objective) در الگوریتم PPO برای مزیت های مثبت و منفی.

الگوریتم PPO با معرفی تابع هدف مقید شده (Clipped Surrogate Objective)، مانع از به روزرسانی های افراطی در سیاست عامل هوشمند می شود. این مکانیزم پایداری محاسباتی بالایی را در مواجهه با بارهای ترافیکی شدید (Traffic Spikes) فراهم می کند. تابع هدف اصلی این الگوریتم به صورت زیر فرمول بندی می گردد:

$$L^{CLIP}(\theta) = \mathbb{E}_t \left[\min(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t) \right] \quad (7)$$

در این ساختار، نسبت احتمال سیاست جدید به قدیم ($r_t(\theta)$) در بازه $[1 - \epsilon, 1 + \epsilon]$ مقید می شود تا گام های بهینه سازی شبکه کاملاً محافظه کارانه و پایدار برداشته شوند. (John Schulman, 2017)

Table 3: **PPO hyperparameters** used for the Mujoco 1 million timestep benchmark.

Hyperparameter	Value
Horizon (T)	512
Adam stepsize	*
Num. epochs	15
Minibatch size	4096
Discount (γ)	0.99
GAE parameter (λ)	0.95
Number of actors	32 (locomotion), 128 (flagrun)
Log stdev. of action distribution	LinearAnneal($-0.7, -1.6$)

همچنین معماری پلتفرم بر پایه ساختار مشترک (Shared Anatomy) هم زمان تابع ارزش و سیاست (Actor-Critic) تنظیم شده و با افزودن بونوس انتروپی، کاوش (Exploration) بهینه در فضای وضعیت شبکه تضمین می شود. (John Schulman, 2017)

اگر از معماری شبکه عصبی استفاده شود که پارامتر ها را بین سیاست - تابع ارزش به اشتراک می گذارد باید از تابع زیانی استفاده کنیم که جایگزین سیاست را با جمله خطای تابع ارزش ترکیب می کند
finite-horizon estimators in [Mni+16]. If using a neural network architecture that shares parameters between the policy and value function, we must use a loss function that combines the policy surrogate and a value function error term. This objective can further be augmented by adding an entropy bonus to ensure sufficient exploration, as suggested in past work [Wil92; Mni+16]. Combining these terms, we obtain the following objective, which is (approximately) maximized each iteration: این تابع هدف می تواند با اضافی کردن یک بونوس انتروپی برای اطمینان از کاوش کافی، بیشتر تقویت شود

$$L_t^{CLIP+VF+S}(\theta) = \hat{\mathbb{E}}_t[L_t^{CLIP}(\theta) - c_1 L_t^{VF}(\theta) + c_2 S[\pi_\theta](s_t)], \quad (9)$$

۳ معماری چارچوب پیشنهادی (تلفیق GNN و یادگیری تقویتی)

هسته اصلی پلتفرم *NeuroBottleneck* در نقطه تلاقی مدل سازی گرافی و یادگیری تقویتی عمیق (DRL+GNN) شکل می گیرد. شبکه های عصبی سنتی (مانند MLP یا CNN) به دلیل داشتن ابعاد ورودی ثابت، توانایی تعمیم پذیری روی توپولوژی های متغیر مخابراتی را ندارند ، همچنین معماری پیشنهادی

با ادغام فرآیند پیام رسانی گرافی (Message Passing) در بدنه عامل هوشمند، این محدودیت را برطرف می‌سازد:

(Paul Almasan, 2022)




Fig. 3: Message passing architecture.

۸ معماری پیام‌رسانی (Message Passing) در شبکه‌های عصبی گراف جهت به‌روزرسانی ویژگی‌های پنهان لینک‌ها.

مسئله مدیریت ترافیک و رفع گلوگاه در این چارچوب به صورت یک فرآیند تصمیم‌گیری مارکوف (MDP) فرمول‌بندی می‌شود:

(Paul Almasan, 2022)

- فضای وضعیت (State Space): وضعیت شبکه شامل ویژگی‌های پویای لینک‌ها (پیکربندی ظرفیت، میزان اشغال فعلی و نرخ اتلاف بسته) و ماتریس ترافیک ورودی است که به عنوان ویژگی‌های اولیه به گراف تزریق می‌شوند.

$$M_k^{t+1} = \sum_{i \in N(k)} m(h_k^t, h_i^t) \quad (1)$$

$$h_k^{t+1} = u(h_k^t, M_k^{t+1}) \quad (2)$$

Notation	Description
x_1	Link available capacity
x_2	Link Betweenness ← Link Bottleneck's
x_3	Action vector (bandwidth allocated)
$x_4 - x_N$	Zero padding

TABLE 1: Input features of the link hidden states. N corresponds to the size of the hidden state vector.

- فضای اقدام (Action Space): به جای تعریف اقدامات روی گره ها یا لینک های ثابت، فضای اقدام بر پایه «مسیرها» (Path-based Action Space) طراحی شده است. (Paul Almasan, 2022)
- ✓ این نوآوری ساختاری اجازه می دهد که عامل هوشمند بدون توجه به ابعاد گراف، گزینه های مسیریابی و توزیع بار را ارزیابی کند و به تعمیم پذیری ۱۰۰ درصدی روی توپولوژی های ندیده برسد. (Paul Almasan, 2022)




Fig. 2: Action representation in the link hidden states.

۹ نحوه بازنمایی فضای اقدام مبتنی بر مسیر در وضعیت پنهان لینک ها.

- تابع پاداش (Reward Function): تابع پاداش سیستم به صورت مستقیم با معیارهای عارضه یابی و گلوگاه شبکه مرتبط است. پاداش باید به گونه ای فرموله می شود که اشغال بیش از حد لینک

های حیاتی ($U_{\{Max\}}$) و تاخیر کل شبکه را کمینه کند؛ در نتیجه عامل یاد می‌گیرد ترافیک را از نواحی پرکنترل به سمت مسیرهای خلوت هدایت نماید. (Paul Almasan, 2022) (عامل هوشمند با در نظر گرفتن ضریب تنزیل (γ)، تلاش می‌کند تا مجموع پاداش های آتی را بیشینه کرده و توازنی میان منافع لحظه ای و پایداری بلند مدت شبکه برقرار کند)




Fig. 1: Schematic representation of the DRL agent in the OTN routing scenario.

• | شماتیک تعامل عامل یادگیری تقویتی عمیق (DRL Agent) و شبکه عصبی گراف در سناریوی مسیریابی و کنترل ترافیک.

۴ ساختار پیاده سازی و مخزن توسعه (مستندات گیت هاب)

جهت تضمین اصالت علمی، توسعه ماژولار و پیاده سازی تمیز و استاندارد در صنعت مخابرات، ساختار مخزن توسعه پروژه با عنوان **NeuroBottleneck** بر پایه نیازمندی های فاز ۱ سازماندهی شده و بر روی پلتفرم گیت هاب پوش (Push) گردیده است.

در فاز ۱، تمرکز اصلی بر اثبات مفهوم (Proof of Concept) و تلفیق ساختارهای گرافی قطعی (نظیر درخت Gomory-Hu) با معماری ترکیبی شبکه های عصبی گراف (GNN) و یادگیری تقویتی عمیق (DRL) بود تا امکان پذیری فنی این طرح در سطح معماری O-RAN اثبات گردد. در این معماری، لایه استخراج وضعیت با استفاده از مدل استقرایی GraphSAGE ساختاردهی شده تا تعمیم پذیری سیستم در مواجهه با تغییرات پویای توپولوژی شبکه تضمین شود. همچنین، مغز متفکر لایه تصمیم گیر بر پایه الگوریتم PPO استوار گردیده تا با بهره گیری از مکانیزم تابع هدف مقید (Clipped Surrogate Objective)، از اعمال تغییرات ناگهانی و مخرب در مسیرهای ترافیکی جلوگیری کرده و پایداری شبکه همراه اول حفظ شود.

جزئیات الگوریتمی شامل تنظیم ابرپارامترها، پیاده سازی ماژول های کنترلی (xApp و rApp) و بهینه سازی دقیق تابع ارزش، مطابق نقشه راه تدوین شده، به امید حق در فاز ۲ و همزمان با توسعه کامل محیط شبیه ساز (Simulator) انجام خواهد شد. این ساختار گیت هاب به عنوان بستر اصلی یکپارچه سازی کدها، نسخه بندی و مستند سازی روند پیشرفت پروژه در فازهای آتی عمل خواهد کرد.

چک لیست ارزیابی کیفی و انطباق استاندارد (سند متمم ۷۰ آیتی)

به منظور حصول اطمینان از کیفیت خروجی های فاز ۱ و تطابق کامل معماری پیشنهادی با الزامات صنعتی، یک چک لیست جامع شامل ۷۰ آیتم کلیدی تدوین و به عنوان متمم به این گزارش الصاق گردیده است.

این سند متمم به عنوان یک ابزار کنترلی دقیق، مطابقت ماژول های NeuroBottleneck را با سطوح خودگردانی ۳GPP/ETSI، استاندارد های واسطه های O-RAN (شامل A1 و E2) و همچنین صحت منطق ریاضیاتی در تلفیق مدل های GraphSAGE و PPO اعتبارسنجی می کند.

تکمیل این چک لیست نشان دهنده بلوغ مفاهیم تئوریک پروژه بوده و به عنوان یک دروازه کیفی معتبر، مسیر گذار از فاز طراحی مفهومی (فاز ۱) به فاز توسعه الگوریتمی و شبیه سازی (فاز ۲) را هموار می سازد.

۵ چشم‌انداز و برنامه‌ریزی توسعه فاز ۲ (شبیه‌سازی و ارزیابی عملی)

هدف اصلی در فاز دوم پروژه NeuroBottleneck، گذار از طراحی معماری و اثبات مفهوم (PoC) به پیاده‌سازی عملیاتی و ارزیابی تجربی مدل‌های پیشنهادی است. در این فاز، ترکیب استقرایی شبکه‌های عصبی گراف (GNN) و الگوریتم یادگیری تقویتی PPO در یک محیط شبیه‌سازی دقیق و تحت سناریوهای ترافیکی پویا مستقر خواهد شد تا کارایی معماری پیشنهادی در کنترل گلوگاه‌های شبکه اثبات گردد.

i. استک تکنولوژی و معماری نرم‌افزاری شبیه‌ساز

پیاده‌سازی محیط شبیه‌ساز بر پایه یکپارچه‌سازی ابزارهای استاندارد توسعه هوش مصنوعی و شبکه‌های نرم‌افزارمحور بنا خواهد شد:

- **موتور یادگیری عمیق و پردازش گراف:** از فریم‌ورک PyTorch و به طور خاص کتابخانه PyTorch Geometric (PyG) جهت پیاده‌سازی ماژول GraphSAGE و استخراج ویژگی‌های توپولوژیک (همگام با مفاهیم Min-cut) استفاده می‌شود.
- **عامل تصمیم‌گیر تقویتی:** الگوریتم PPO به کمک فریم‌ورک Stable Baselines3 پیاده‌سازی می‌گردد که ثبات بالایی در تنظیم تابع هدف مقید و همگرایی سیاست‌ها ارائه می‌دهد.
- **واسط تعاملی (Environment):** ارتباط بین شبکه‌های مخابراتی و عامل هوشمند از طریق توسعه یک محیط سفارشی در Gymnasium برقرار می‌شود که در هر گام (Step)، وضعیت شبکه را دریافت و اقدامات کنترلی را اعمال می‌کند.
- **تولید تله‌متری و شبیه‌سازی شبکه:** برای شبیه‌سازی جریان‌های ترافیکی و استخراج داده‌های وضعیت، از ابزارهایی نظیر Mininet (در کنار کنترلر Ryu) جهت مدیریت دقیق جریان‌های داده استفاده خواهد شد.

ii. سناریوهای ارزیابی و استقرار (Test Cases)

- برای اعتبارسنجی قابلیت‌های مدل در محیط O-RAN، سناریوهای زیر طراحی و اجرا خواهند شد:
- **تغییرات پویای توپولوژی:** ارزیابی توانایی مدل استقرایی GraphSAGE در مواجهه با قطعی ناگهانی لینک‌ها یا اضافه شدن نودهای جدید به شبکه بدون نیاز به آموزش مجدد (Zero-shot Generalization).

- مدیریت تراکم (Congestion Management): تزریق ترافیک های ناگهانی (Burst Traffic) در مسیرهای خاص برای سنجش سرعت واکنش الگوریتم PPO در بازتوزیع بار ترافیکی و جلوگیری از افت بسته ها.
- تطابق با حلقه های کنترلی (Control Loops): استقرار ماژول ها در قالب xApp (برای تصمیمات زمان حقیقی نزدیک به Near-RT) جهت بررسی تاخیر پردازشی مدل.

iii. شاخص های کلیدی عملکرد (KPIs)

- عملکرد عامل هوشمند در فاز ۲ بر اساس متریک های زیر بهینه سازی و سنجیده خواهد شد:
۱. توان عملیاتی شبکه (Network Throughput): بررسی میزان افزایش ظرفیت انتقال داده نسبت به الگوریتم های مسیریابی سنتی (مانند OSPF یا ECMP).
 ۲. تاخیر انتها به انتها (End-to-End Latency): ارزیابی موفقیت مدل در انتخاب کوتاه ترین و خلوت ترین مسیرها.
 ۳. پایداری و سرعت همگرایی (Convergence Rate): پایش نمودارهای تابع زیان (Loss) و پاداش تجمعی (Cumulative Reward) در ابزاری نظیر Biases & Weights برای اثبات پایداری آموزش PPO.

iv. مراحل اجرا و یکپارچه سازی

- مسیر توسعه فاز ۲ شامل چهار گام اساسی خواهد بود:
- ۱) پیکربندی و راه اندازی بستر شبیه ساز شبکه و واسط Gymnasium؛
 - ۲) پیاده سازی سیستم پیام رسانی گراف و استخراج Embedding ها؛
 - ۳) آموزش حلقه بسته عامل PPO بر روی داده های تله متری؛
- و در نهایت
- ۴) مستند سازی کد های توسعه یافته و ثبت نتایج در مخزن گیت هاب پروژه.